

LAPORAN KURASI DATASET CITRA & DATA SHEET (DATA CARD)

Computer Vision & Deep Learning — Modul 06: Persiapan Dataset Citra

LEMBAR KERJA PRAKTIKUM / LAPORAN TUGAS	IDENTITAS MAHASISWA / PEMBUAT
Dokumen: Dataset Curation Report & Datasheet Topik: CassavaCare AI Dataset Pipeline Mata Kuliah: Intelligent Mobile & Web Application Development Dosen Pengampu: Edwin Hari Agus Prastyo, S.Kom., M.Kom.	Nama Mahasiswa: ALDI TUNGGAL JAYA NIM: 2395114002 Program Studi: Teknik Informatika (S1) Semester / T.A.: Ganjil 2025/2026 Status: Submisi Terisi Lengkap

BAB I: DESKRIPSI DOMAIN, MASALAH, & AKUISISI DATA

Tanaman singkong (*Manihot esculenta Crantz*) merupakan sumber karbohidrat terbesar ketiga di dunia dan makanan pokok bagi lebih dari 500 juta jiwa. Namun, produktivitas pertanian singkong terancam secara masif oleh infeksi virus dan serangga hama yang dapat menyebabkan kehilangan hasil panen hingga \$1 miliar USD per tahun. Aplikasi **CassavaCare AI** dirancang untuk mendeteksi 3 penyakit virus utama dan 2 jenis kerusakan hama pada daun singkong langsung di lapangan (*on-device*) tanpa membutuhkan koneksi internet.

Sumber & Strategi Akuisisi Data:

- Benchmark Utama (Ramcharan et al., 2017):** Dataset citra daun singkong terpublikasi (*Frontiers in Plant Science*, DOI: 10.3389/fpls.2017.01852) yang diambil di kebun percobaan IITA Bagamoyo, Tanzania.
- Pengumpulan Mandiri (Primary Field Data):** Foto daun singkong otentik menggunakan kamera smartphone (1080p s.d. 4K) pada variasi pencahayaan alami (pagi, siang terik, temaram sore) di lahan lokal.

BAB II: DATASET DATASHEET (DATA CARD - GEBRU ET AL., 2021)

Sesuai standar ilmiah internasional (*Datasheets for Datasets*, Gebru et al., 2021), berikut adalah lembar fakta dataset **CassavaCare AI**:

Elemen Data Card	Deskripsi Spasial & Spesifikasi Teknis
1. Motivasi Pengumpulan	Melatih model Computer Vision ringan (Inception v3 / MobileNet / CNN Custom) untuk mengklasifikasikan penyakit daun singkong secara presisi.
2. Komposisi Citra & Distribusi	- Total Citra Utuh (Original Dataset): 2,756 citra RGB. - Total Leaflet Cropped: 15,000 citra potongan helai daun. - Sebaran Kelas: CBSD (398 / 14.4%), CMD (388 / 14.1%), BLS (386 / 14.0%), GMD (309 / 11.2%), RMD (415 / 15.1%), Healthy (860 / 31.2%). - Resolusi Asli: 1920x1080 px hingga 5184x3888 px.
3. Proses Pengumpulan	Kamera Sony Cybershot 20.2MP & Smartphone Sony IMX 64MP. Waktu: 07.30 - 16.30 WIB dengan variasi sudut (top-down, 45-degree angle, close-up).
4. Pra-Pengolahan & Anotasi	Anotasi tervalidasi oleh pakar penyakit tanaman IITA disandingkan dengan anotasi mandiri via Make Sense (makesense.ai) untuk format YOLO (.txt) & ImageFolder.
5. Keterbatasan & Bias	Latar belakang foto mencakup tanah, bayangan, tangan manusia, dan dedaunan sekitar. Belum mencakup foto malam hari dengan flash buatan.

BAB III: PIPELINE STANDARISASI, DATA HYGIENE, & KODE PYTORCH

3.1 Audit Kebersihan Data (Data Hygiene & Anti-Data Leakage):

- **Eliminasi Corrupt JPEG:** Skrip `PIL.Image.verify()` mendeteksi dan mengeliminasi byte terpotong yang berpotensi memutus training loop.
- **Deduplikasi MD5 Hash:** Mencegah kebocoran data (data leakage) antara subset latih dan uji menggunakan hashing MD5 `hashlib.md5()`.
- **Pemisahan Deterministik (Aturan Emas):** Dataset dibagi terlebih dahulu (Split First) menjadi **Train 70%, Val 15%**, dan **Test 15%** dengan random seed (42). Augmentasi acak hanya diterapkan pada subset Train.

3.2 Cuplikan Kode Pipeline PyTorch (curation_pipeline.py):

```
import os, random, hashlib, torch, numpy as np
from torchvision import datasets, transforms
from torch.utils.data import DataLoader, random_split

# 1. Reproducibility Seed Setup
SEED = 42
torch.manual_seed(SEED)

# 2. Augmentasi Dinamis (Khusus Train)
train_transforms = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.RandomHorizontalFlip(p=0.5),
    transforms.RandomRotation(degrees=15),
    transforms.ColorJitter(brightness=0.2, contrast=0.2),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
])

# 3. Evaluasi Murni (Khusus Val & Test)
val_transforms = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
])
```

BAB IV: ANALISIS BIAS VISUAL, SHORTCUT LEARNING, & MITIGASI

4.1 Risiko Bias Visual & Shortcut Learning:

Model Deep Learning berisiko tinggi mengalami *shortcut learning*—mempelajari korelasi latar belakang (seperti keberadaan tangan manusia, warna tanah, atau bayangan) alih-alih fitur fisiologis daun.

4.2 Strategi Mitigasi Teruji:

- **RandomResizedCrop (scale 0.8 s.d. 1.0):** Memaksa model berfokus pada tekstur helai daun (leaflet) dan pola klorosis vena.
- **ColorJitter Kontrol:** Melatih ketahanan model terhadap variasi pencahayaan terik matahari tanpa merusak spektrum warna diagnostik.
- **Weighted Cross-Entropy Loss:** Memberikan pembobotan penalti kesalahan lebih tinggi pada kelas minoritas (GMD / CBSD) untuk mengatasi ketimpangan distribusi data.